

16: Approximating Max Cut

בעיית $max-cut$: בהינתן גרף G , נרצה למצוא חלוקה של הקודקודים לשתי קבוצות זרות $(S, V(G) \setminus S)$ שממקסמת את $e_G(S, V(G) \setminus S)$.

משפט: בגרף G , גודל החתך המקסימום הוא לפחות $e(G)/2$.

נגזר מכך, שלכל גרף יש תת-גרף דו"צ פורש, עם לפחות $e(G)/2$ צלעות.

כלומר אפשר למצוא חלוקה של קודקודי הגרף לשתי קבוצות ותת-קבוצה בגודל $e(G)/2$ של הצלעות, כך שכל הצלעות הן רק בין הקבוצות.


הוכחה: באינדוקציה על $v(G)$.

בסיס: עבור קודקוד 1 או 2, הטענה טריוויאלית.

צעד: נניח שהטענה מתקיימת עבור כל גרף G' עם $v(G') < n$, ונוכיח עבור גרף G עם $v(G) = n$:

נבחר קודקוד $v \in V(G)$ שרירותי, ונתבונן ב- $G - v$:

ניקה את החלוקה שקיימת ב- $G - v$ לפי הנ"א: $(S, V(G) \setminus (S \cup \{v\}))$. יש בין הקבוצות $e(G - v)/2$ צלעות, לפי הנ"א.



נוסיף את v חזרה, לקבוצה שבה יש לו פחות שכנים. כלומר, מוסיפים לחתך לפחות $(\deg_G v)/2$ צלעות.

אז גודל החתך שנוצר אחרי ההוספה הוא לפחות:

$$\frac{e(G - v)}{2} + \frac{\deg_G v}{2} = \frac{e(G - v) + \deg_G v}{2} = \frac{e(G)}{2}$$

כנדרש.

ההוכחה הזו נותנת לנו אלגוריתם פולינומי שהוא 0.5-מקרב לבעיית $max-cut$. האלגוריתם מגיע דרך תהליך $de-randomization$. התהליך של $de-randomization$ הוא בניית אלגוריתם מקרי (שזה תהליך הרבה יותר קל) ואז המרת האלגוריתם למבנה דטרמיניסטי.

בניית רנדומית

נבנה אלגוריתם אקראי ל- $max-cut$:

1. נאתחל $A := \emptyset, B := \emptyset$.

2. לכל קודקוד $v \in V(G)$, נטיל מטבע הוגן (כל ההטלות בת"ל):

a . אם יצא עץ, נשים את הקודקוד ב- A . אחרת, ב- B .

ניתוח האלגוריתם: מה ההסתברות שהאלגוריתם מוציא חתך בגודל לפחות $e(G)/2$.

טענה: ההסתברות היא לפחות $1/\left(\frac{e(G)}{2} + 1\right)$. זו לא הסתברות טובה, אבל האלגוריתם הזה הוא רק הבסיס.

הוכחה: נצטרך כמה טענות עזר:

עבור צלע $e \in E(G)$, נגדיר את האינדיקטור לכך ש- e חוצה את החתך:

$$X_e := \begin{cases} 1, & e \in E_G(A, B) \\ 0, & e \notin E_G(A, B) \end{cases}$$

עבור צלע $uv := e$, מתקיים:

$$\mathbb{E}[X_e] = \mathbb{P}[u \in A \wedge v \in B] + \mathbb{P}[u \in B \wedge v \in A] = 1/4 + 1/4 = 1/2$$

כי המיקומים נקבעים לפי מטבעות הוגנים בת"ל. נוכל לרשום:

$$e_G(A, B) = \sum_{e \in E(G)} X_e$$

כלומר, הגודל של החתך יהיה מספר הצלעות שהאינדיקטור שלהן יצא 1.

אזי, לפי לינאריות התוחלת נקבל:

16: Approximating Max Cut

$$\mathbb{E}[e_G(A, B)] = \sum_{e \in E(G)} \mathbb{E}[X_e] = \frac{e(G)}{2}$$

נחזור להוכחה: אנחנו רוצים לחסום מלמטה את:

$$p := \mathbb{P}[e_G(A, B) \geq e(G)/2]$$

נמצא את הביטוי הזה בתוך התוחלת. מתקיים:

$$e(G)/2 = \mathbb{E}[e_G(A, B)] =$$

נחשב את התוחלת לפי הגדרה, ונפצל את הסכום לשניים:

$$= \sum_{i \leq \frac{e(G)}{2} - 1} i \cdot \mathbb{P}[e_G(A, B) = i] + \sum_{i \geq \frac{e(G)}{2}} i \cdot \mathbb{P}[e_G(A, B) = i] \leq$$

ננתח את צד שמאל: אם נשתמש רק ב- i הכי גדול בו, נקבל ביטוי שחוסם אותו מלמעלה:

$$\leq \left(\frac{e(G)}{2} - 1 \right) \underbrace{\sum_{i \leq \frac{e(G)}{2} - 1} \mathbb{P}[e_G(A, B) = i]}_{1-p} + \sum_{i \geq \frac{e(G)}{2}} i \cdot \mathbb{P}[e_G(A, B) = i] \leq$$

כל החלק המסומן, זה ההסתברות המשלימה למצב שאנחנו מחפשים. כלומר זה $1 - p$.

נעשה דבר דומה גם בצד ימין: הערך הכי גדול ש- i יכול לקבל זה $e(G)$:

$$\leq \left(\frac{e(G)}{2} - 1 \right) (1 - p) + e(G) \cdot \underbrace{\sum_{i \geq \frac{e(G)}{2}} \mathbb{P}[e_G(A, B) = i]}_p = \left(\frac{e(G)}{2} - 1 \right) (1 - p) + e(G)p$$

בסה"כ, הראנו ש:

$$\frac{e(G)}{2} \leq \left(\frac{e(G)}{2} - 1 \right) (1 - p) + e(G)p$$

נבודד את p ונקבל שאכן הוא חסום מלמטה כמו שרצינו.

קצת הסתברות

במרחב הסתברות כשלהו, נאמר שאירוע \mathcal{E} הוא **מדיד** (*measurable*) אם $\mathbb{P}[\mathcal{E}]$ מוגדרת.

ההסתברות $\mathbb{P}[\mathcal{E}] = 0$ היא מוגדרת היטב.

עבור מאורעות B, A כך ש $\mathbb{P}[B] > 0$ נרשום:

$$\mathbb{P}[A|B] := \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}, \quad \mathbb{P}[B] \cdot \mathbb{P}[A|B] := \mathbb{P}[A \cap B]$$

ועבור חלוקה בת מניה: $B = B_1 \cup B_2 \cup \dots$, מתקיים:

$$\mathbb{P}[A] = \sum_{i: \mathbb{P}[B_i] > 0} \mathbb{P}[A|B_i] \cdot \mathbb{P}[B_i] = \sum_i \mathbb{P}[A \cap B_i]$$

עבור מ"מ X, Y בדידים, וערך y בטווח של Y :

$$\mathbb{E}[X | Y = y] := \sum_x x \cdot \mathbb{P}[X = x | Y = y]$$


$\mathbb{E}[X | Y]$ זה הפונקציה:

$$y \longmapsto \mathbb{E}[X | Y = y]$$

לפעמים נרשום $\mathbb{E}[X | Y](y)$ במקום $\mathbb{E}[X | Y = y]$.


Y מחלק את העולם לקבוצות *level-sets*:

16: Approximating Max Cut




ההסתברות (measure) של $level-set$ היא: $\mathbb{P}[Y = y_i]$.

נוסיף את X , עם ה- $level-sets$ שלו, ונשים לב שהחלוקות של X ו- Y מעדנות אחת את השנייה:



אז התוחלת המותנית:



וחוק התוחלת השלימה:


$$\mathbb{E}[X] = \sum_{y \in \text{supp}(Y)} \mathbb{E}[X | Y = y] \cdot \mathbb{P}[Y = y]$$

חזרה ל- $Max-cut$, ביצוע $de-randomization$

היה לנו אלגוריתם אקראי, וחסמנו מלמטה את ההסתברות שהוא מצליח. נשתמש בתוחלת המותנית כדי להוציא מהאלגוריתם את האקראיות.

יהי $\{v_1, v_2, \dots, v_n\}$ את הסדר שבו עברנו על הקודקודים באלגוריתם הרנדומי.

נתבונן במצב שבו $\{v_1, v_2, \dots, v_i\}$ כבר מוקמו בקבוצות A ו- B . נשקול את הרגע שבו מטילים מטבע עבור v_{i+1} :



לפי נוסחת התוחלת השלימה, התוחלת של מספר הצלעות בחתך בהינתן שכבר מיקמנו את $\{v_1, v_2, \dots, v_i\}$:

$$\mathbb{E}[e_G(A, B) | v_1, \dots, v_i \text{ placed}] =$$

$$= \underbrace{\mathbb{P}[v_{i+1} \in A]}_{0.5} \cdot \mathbb{E}[e_G(A, B) | v_1, \dots, v_i \text{ placed} \wedge v_{i+1} \in A] + \underbrace{\mathbb{P}[v_{i+1} \in B]}_{0.5} \cdot \mathbb{E}[e_G(A, B) | v_1, \dots, v_i \text{ placed} \wedge v_{i+1} \in B] =$$

$$= 0.5 \cdot \left(\underbrace{\mathbb{E}[e_G(A, B) | v_1, \dots, v_i \text{ placed} \wedge v_{i+1} \in A]}_{E_A} + \underbrace{\mathbb{E}[e_G(A, B) | v_1, \dots, v_i \text{ placed} \wedge v_{i+1} \in B]}_{E_B} \right)$$

נסמן את התוחלת \mathbb{E} . יש לנו את המבנה: $2\mathbb{E} = E_A + E_B \Rightarrow \mathbb{E} = (E_A + E_B)/2$.

16: Approximating Max Cut

כלומר, $E_A \geq \mathbb{E}$ או $E_B \geq \mathbb{E}$. (כי אם שניהם קטנים יותר, הסכום שלהם לא יעלה על $2\mathbb{E}$).

כלומר: לפחות אחת האופציות לא מקטינה את התוחלת המותנית. לפי העיקרון הזה, נבנה אלגוריתם דטרמיניסטי:

1. יהי v_1, v_2, \dots, v_n סדר כלשהו של הקודקודים.

2. נאתחל $A = B = \emptyset$.

3. עבור $i = 1$ עד n :

a. נחשב את E_A, E_B . (אח"כ נסביר איך).

b. אם $E_A > E_B$, נשים את v_i ב- A . אחרת, נשים אותו ב- B .

נוכיח שהאלגוריתם לעיל תמיד מייצר חתך בגודל לפחות $e(G)/2$:

כבר הראנו ש- $e(G)/2 \leq \mathbb{E}[e_G(A, B)]$.

והראינו שכל צעד לא מקטין את התוחלת המותנית. כלומר:

$$\mathbb{E}[e_G(A, B)] \leq \mathbb{E}[e_G(A, B) \mid v_1 \text{ is placed}] \leq \mathbb{E}[e_G(A, B) \mid v_1, v_2 \text{ are placed}] \leq \dots \leq \mathbb{E}[e_G(A, B) \mid v_1, v_2, \dots, v_n \text{ are placed}]$$

והשלב האחרון זה אחרי שמיקמנו את כל הנקודות. בסה"כ, קיבלנו שהתוחלת של $e_G(A, B)$ היא לפחות $e(G)/2$, גם בסוף האלגוריתם.

חישוב E_A, E_B

נגדיר את \tilde{A}, \tilde{B} ונפריד ביניהם לבין B, A :


בשלב אחרי שמיקמנו את v_1, \dots, v_i , נאמר ש- \tilde{A}, \tilde{B} זה מה שאנחנו רואים ב- B, A באותו הרגע. A ו- B הם בשביל המשתנה המקרי $e_G(A, B)$.

נשקול מה קורה עבור v_{i+1} : נרצה לחשב את E_A, E_B כדי שנדע לאיזה צד להכניס אותו. על מה בעצם לוקחים תוחלת מותנית?

\tilde{A}, \tilde{B} כבר מקובעים, ואנחנו יודעים איזה צלעות יש ביניהם, ואיזה צלעות יש בין v_{i+1} לכל אחד מ- \tilde{A}, \tilde{B} .

מה שעדיין לא קבוע, הם הצלעות שמחוברות ל- v_{i+2}, \dots, v_n . נסמן את הכמות של הצלעות האלה ℓ :

$$\ell := e(G) - \underbrace{\deg_G(v_{i+1}, \tilde{A})}_a - \underbrace{\deg_G(v_{i+1}, \tilde{B})}_b - \underbrace{e_G(\tilde{A})}_g - \underbrace{e_G(\tilde{B})}_d - \underbrace{e_G(\tilde{A}, \tilde{B})}_h$$



E_A זה התוחלת של גודל החתך, עבור המצב הנוכחי ותחת ההנחה ששמנו את v_{i+1} ב- A .

שזה שווה למספר הצלעות הנוכחי בחתך, ועוד מספר הצלעות שיש בין v_{i+1} ל- \tilde{B} , ועוד התוחלת של מספר הצלעות הלא-קבועות שיחצו את החתך – שזה חצי מהן.

$$E_A := \mathbb{E}[e_G(A, B) \mid v_1, \dots, v_i \text{ are placed} \wedge v_{i+1} \in A] = e_G(\tilde{A}, \tilde{B}) + \deg_G(v_{i+1}, \tilde{B}) + \ell/2$$

$$E_B := \mathbb{E}[e_G(A, B) \mid v_1, \dots, v_i \text{ are placed} \wedge v_{i+1} \in B] = e_G(\tilde{A}, \tilde{B}) + \deg_G(v_{i+1}, \tilde{A}) + \ell/2$$

אז ההבדל בין E_A ל- E_B הוא רק ההבדל בין הדרגות:

$$|E_A - E_B| = |\deg_G(v_{i+1}, \tilde{B}) - \deg_G(v_{i+1}, \tilde{A})|$$

אז אפשר לבדוק רק איזה מהדרגות גדולה יותר. וזה בדיוק האלגוריתם הראשון שראינו.